¿CNN o Transformer para radiografías de tórax?

Comparación de DenseNet121, ResNet18 y ViT-B/16 en NIH ChestX-ray14

Alfredo Gallegos · Universidad Panamericana, Aguascalientes · Proyecto Final de Deep Learning · Octubre 2026

14 hallazgos, varios por imagen y muy desbalanceados

112,120

radiografías frontales

30,805

pacientes

14

hallazgos (multi-etiqueta)

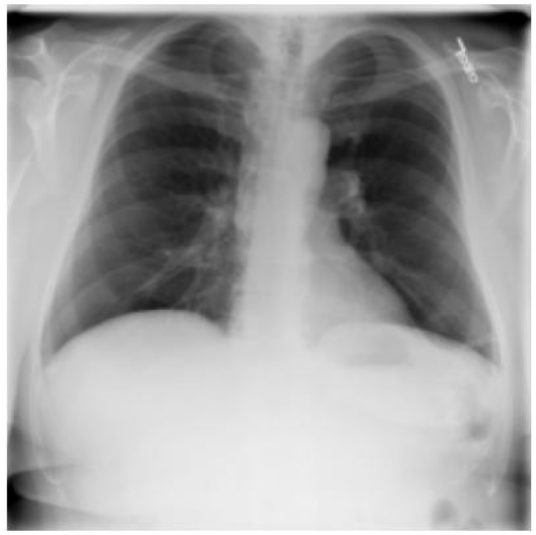
0.2–18%

prevalencia por hallazgo

Pneumothorax, Consolidation, Emphysema



Atelectasis



Atelectasis, Effusion, Infiltration



Atelectasis, Infiltration



Mismo protocolo y mismo presupuesto para los tres modelos

1

Datos

12,000 imágenes al azar; split por paciente 70/15/15 (8,400 de entrenamiento), ningún paciente en dos conjuntos

2

Entrada

1024 → 224 px, normalización ImageNet, volteo horizontal

3

Entrenamiento

Pesos de ImageNet; solo el último bloque + capa de 14 salidas. Adam 1e-4, 5 épocas, mejor época en validación

4

Evaluación

AUROC por clase, F1 con umbral elegido en validación, IC 95% por bootstrap y comparación pareada

DenseNet121

CNN · conexiones densas (base de CheXNet)
7.0M parámetros · 2.2M entrenables

ResNet18

CNN · conexiones residuales
11.2M parámetros · 8.4M entrenables

ViT-B/16

Transformer · 12 bloques de auto-atención
85.8M parámetros · 7.1M entrenables

Los tres modelos rinden casi igual (AUROC 0.74–0.76)

Modelo	AUROC macro [IC 95%]	F1 macro	F1 micro	Mejor época
DenseNet121	0.742 [0.717, 0.767]	0.185	0.248	2
ResNet18	**0.760 [0.736, 0.781]**	0.186	0.264	2
ViT-B/16	0.745 [0.718, 0.769]	0.186	0.249	3

Diferencias significativas (AUROC)

ResNet18 > DenseNet121 (+0.018)

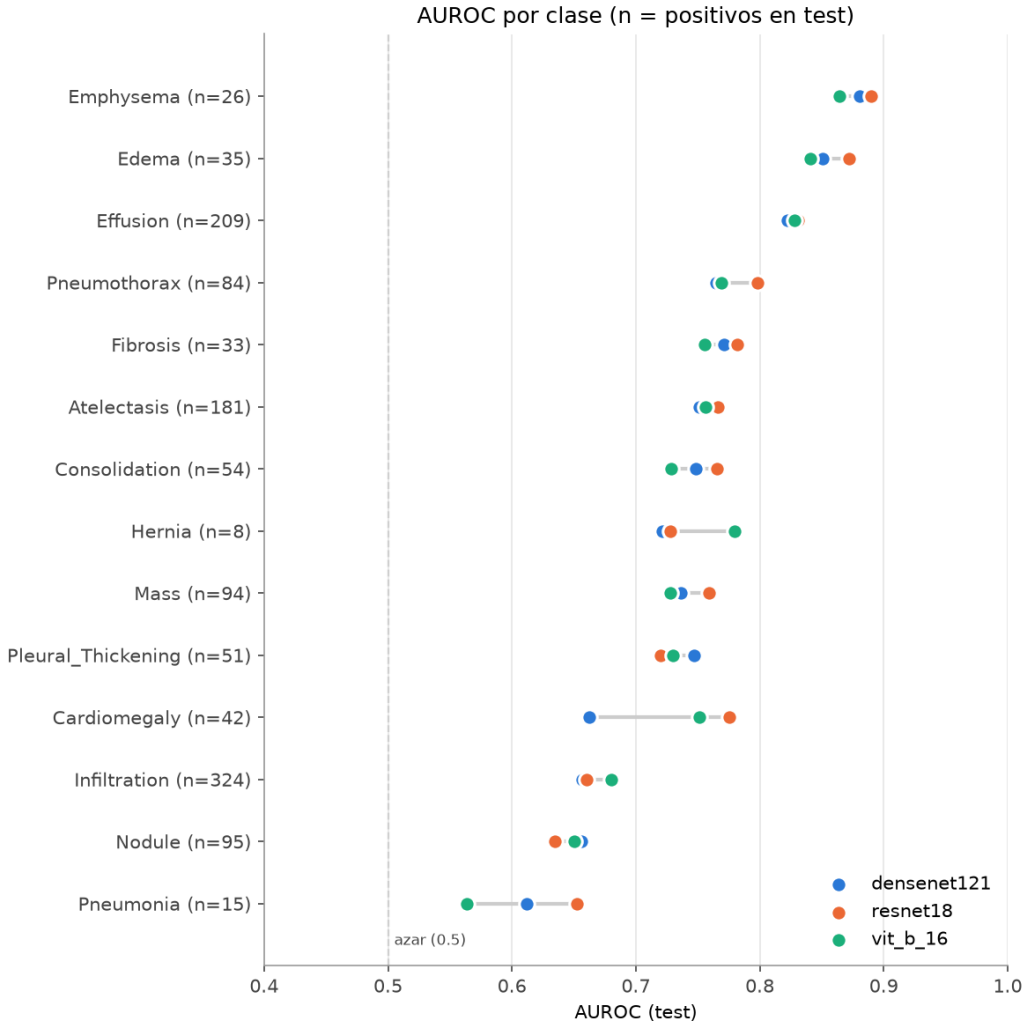
La exactitud no distingue

Los tres ≈ 0.950, igual que predecir siempre "sin hallazgo" (0.950)

Umbral elegido en validación

F1 macro: ~0.04 con umbral 0.5, ~0.19 con umbral ajustado

Por hallazgo, la dificultad pesa más que la arquitectura



Más fáciles

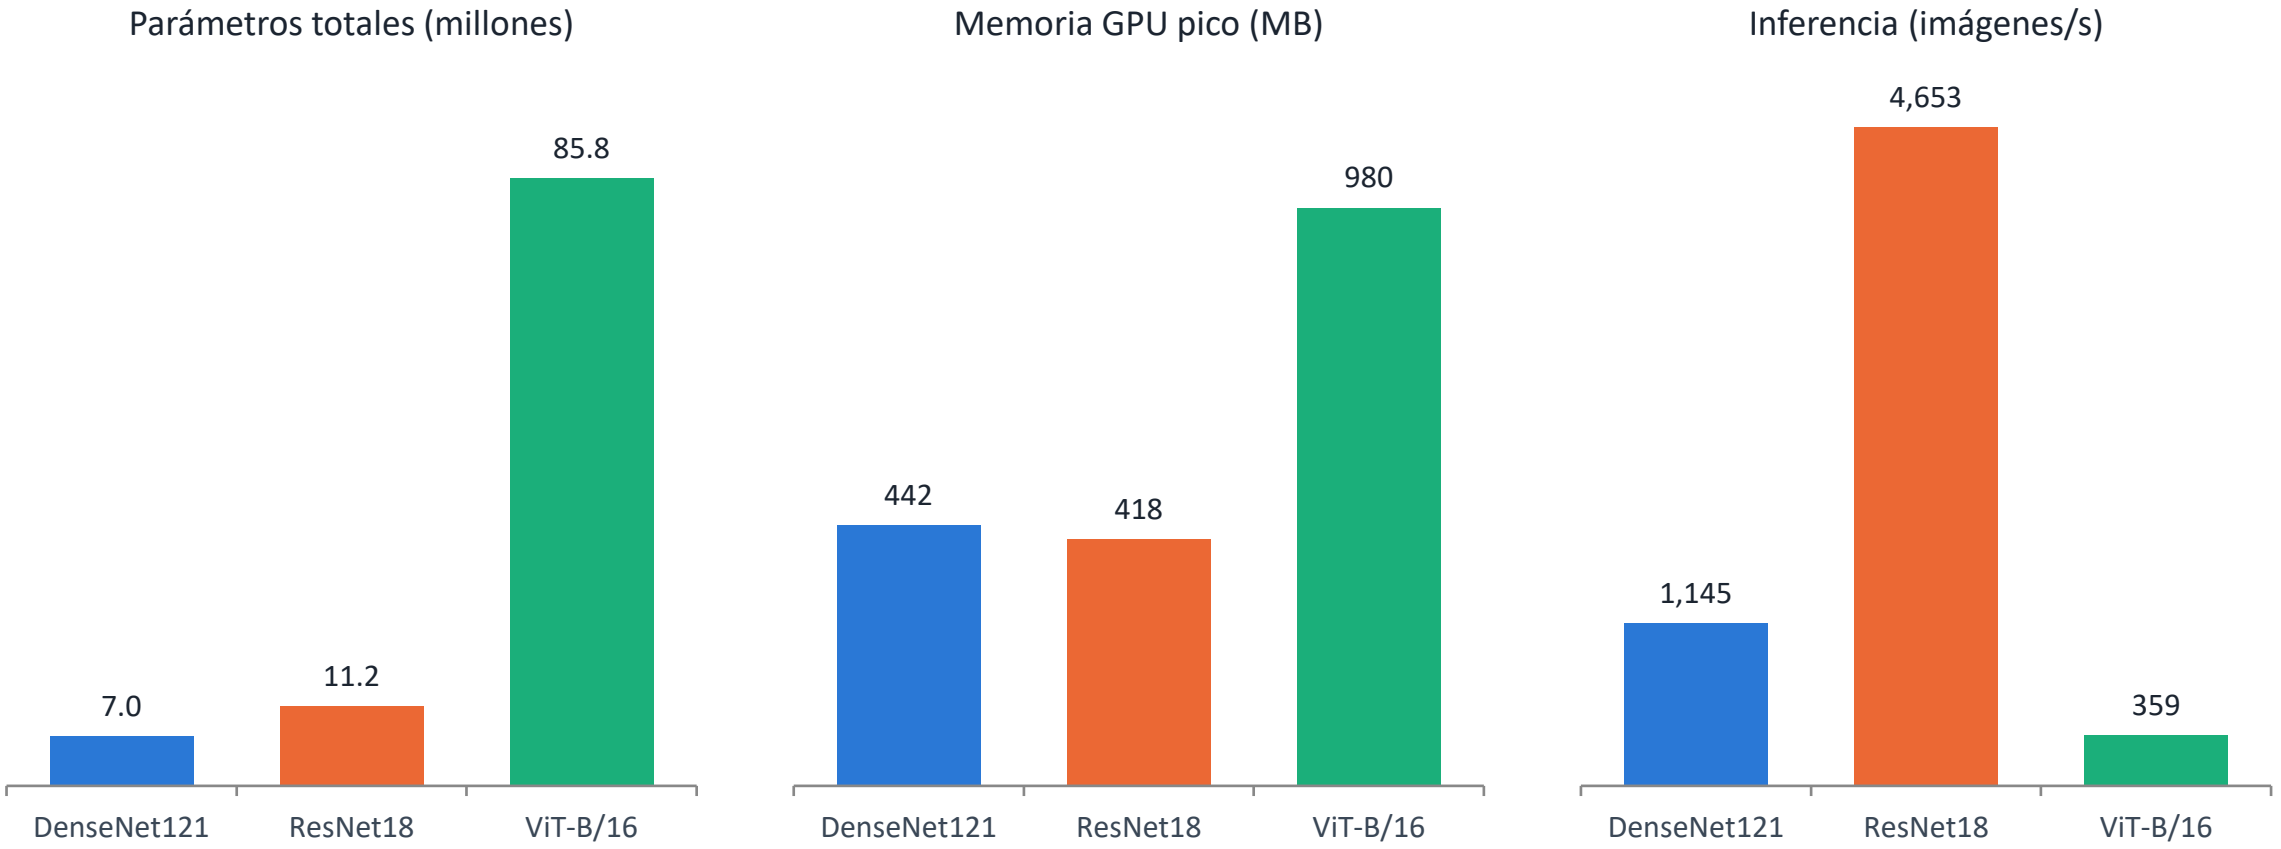
- Emphysema: 0.88
- Edema: 0.85
- Effusion: 0.83

Más difíciles

- Pneumonia: 0.61
- Nodule: 0.65
- Infiltration: 0.67

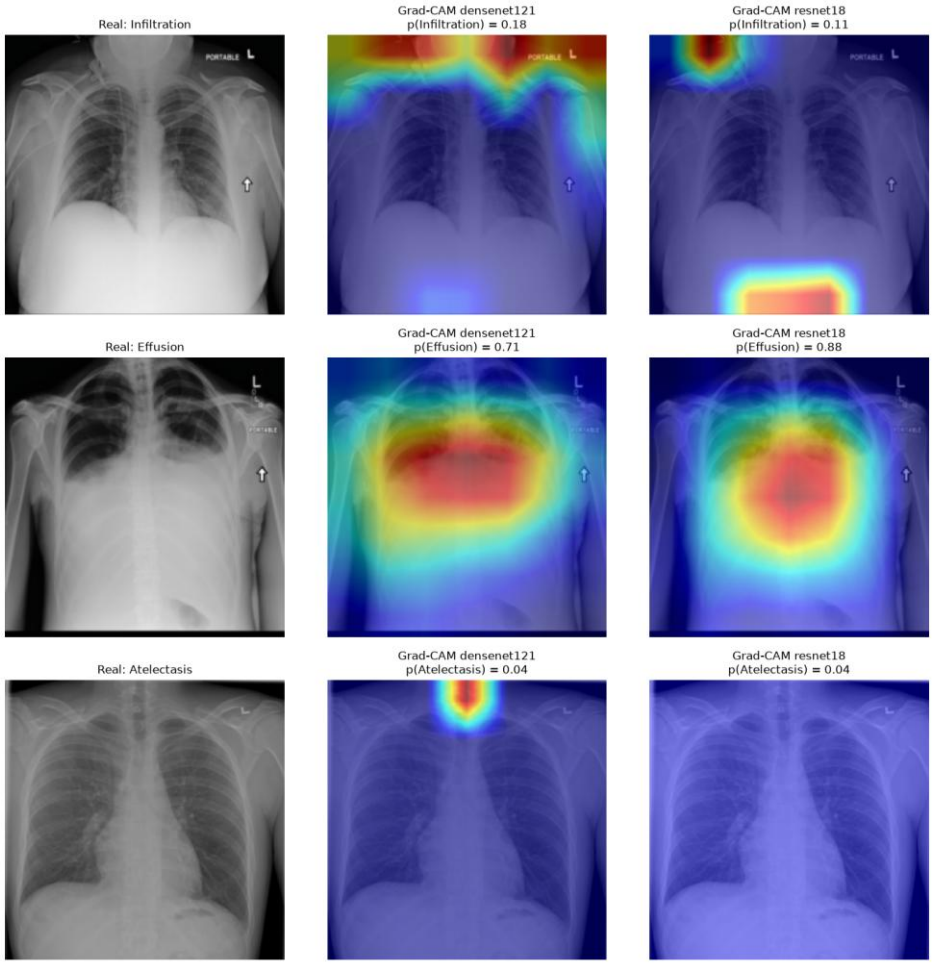
Promedio de los tres modelos. Los hallazgos con pocos positivos en prueba (p. ej. Hernia) tienen estimaciones inestables.

ViT-B/16: 12× los parámetros y 13× más lento que ResNet18

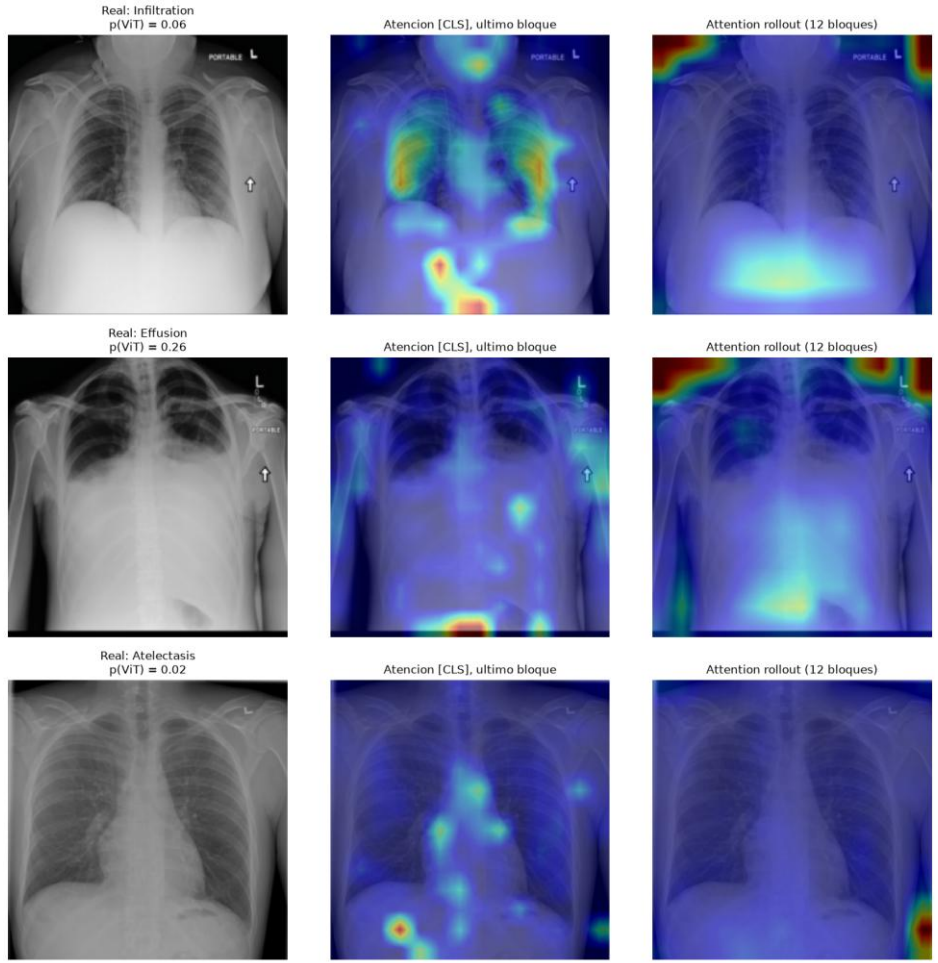


Con AUROC dentro de 0.02 entre los tres, ResNet18 es el mejor compromiso: el más rápido y el que menos memoria usa. Tiempo por época: DenseNet121 41 s · ResNet18 44 s · ViT-B/16 58 s.

¿Dónde miran los modelos?



Grad-CAM (DenseNet121, ResNet18) para la clase real



ViT-B/16: atención del último bloque y attention rollout

Conclusiones

Desempeño
Los tres modelos rinden casi igual (AUROC 0.74–0.76); la dificultad depende más del hallazgo que de la arquitectura.

Costo
ResNet18 es el mejor compromiso. El ViT cuesta 12× en parámetros y 13× en tiempo de inferencia sin rendir más.

Método
Split por paciente, umbral elegido en validación e intervalos de confianza: sin ellos, las conclusiones habrían sido engañosas.

Limitaciones: subconjunto de 12k imágenes (11%), etiquetas ruidosas, 5 épocas con backbone casi congelado, una sola semilla, 224 px. Trabajo futuro: las 112k imágenes, fine-tuning completo, varias semillas, mayor resolución y evaluar la localización con las cajas de ChestX-ray14.