¿CNN, Transformer o híbrido para radiografías de tórax?

Comparación de DenseNet121, ResNet18, ViT-B/16, MaxViT-T (híbrido) y un ensemble en NIH ChestX-ray14

Alfredo Gallegos López · Universidad Panamericana, Aguascalientes · Proyecto Final de Deep Learning · Octubre 2026

14 hallazgos, varios por imagen y muy desbalanceados

112,120

radiografías frontales

30,805

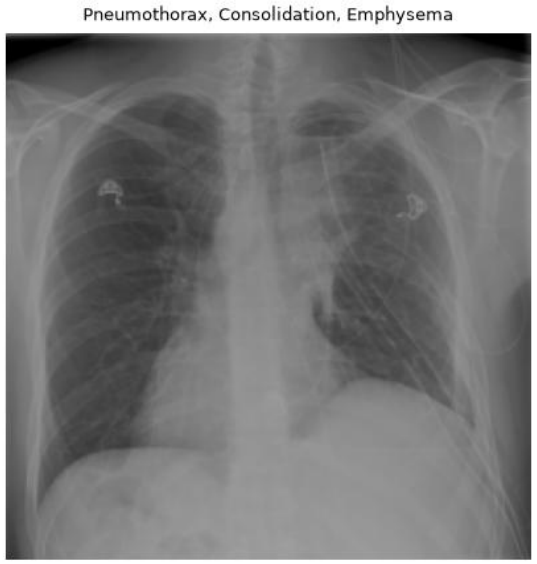
pacientes

14

hallazgos (multi-etiqueta)

0.2–18%

prevalencia por hallazgo









Mismo protocolo y mismo presupuesto para los cuatro modelos

1

Datos

12,000 imágenes al azar; split por paciente 70/15/15 (8,400 de entrenamiento)

2

Entrada

1024 → 224 px, normalización ImageNet, volteo horizontal; desbalance tratado con AUROC y umbral por clase

3

Entrenamiento

Pesos de ImageNet; solo el último bloque + capa de 14 salidas. Adam 1e-4, 5 épocas, mejor época en validación

4

Evaluación

AUROC, F1 (umbral elegido en validación), exactitud, IC 95% por bootstrap y comparación pareada

DenseNet121

CNN · conexiones densas (base de CheXNet) · 7.0M parám. (2.2M entrenables)

ResNet18

CNN · conexiones residuales · 11.2M parám. (8.4M entrenables)

ViT-B/16

Transformer · 12 bloques de auto-atención · 85.8M parám. (7.1M entrenables)

MaxViT-T

Híbrido · convoluciones + atención local y global · 30.4M parám. (9.2M entrenables)

+ Ensemble: promedio de las probabilidades de los cuatro, sin entrenamiento adicional

Ninguna arquitectura domina; el ensemble mejora a todas

Modelo	AUROC macro [IC 95%]	F1 macro	F1 micro	Exactitud	Mejor época
DenseNet121	0.745 [0.721, 0.768]	0.188	0.253	0.950	3
ResNet18	0.749 [0.725, 0.771]	0.197	0.266	0.950	2
ViT-B/16	0.742 [0.717, 0.766]	0.194	0.274	0.950	3
MaxViT-T	0.733 [0.705, 0.759]	0.172	0.252	0.950	5
Ensemble	**0.767 [0.740, 0.791]**	**0.204**	**0.310**	0.950	–

Entre modelos individuales

Ninguna diferencia de AUROC es significativa

Ensemble vs. cada modelo

+0.018 a +0.034 de AUROC, todas significativas

La exactitud no distingue

Todos ≈ 0.950, igual que predecir siempre "sin hallazgo"

Una repetición independiente del experimento cambió el orden de los modelos individuales (hasta 0.010 de AUROC).

El ensemble mejora a todos; el híbrido no convergió

Ensemble de los 4 modelos

0.767

AUROC macro
+0.018 a +0.034 sobre cada modelo

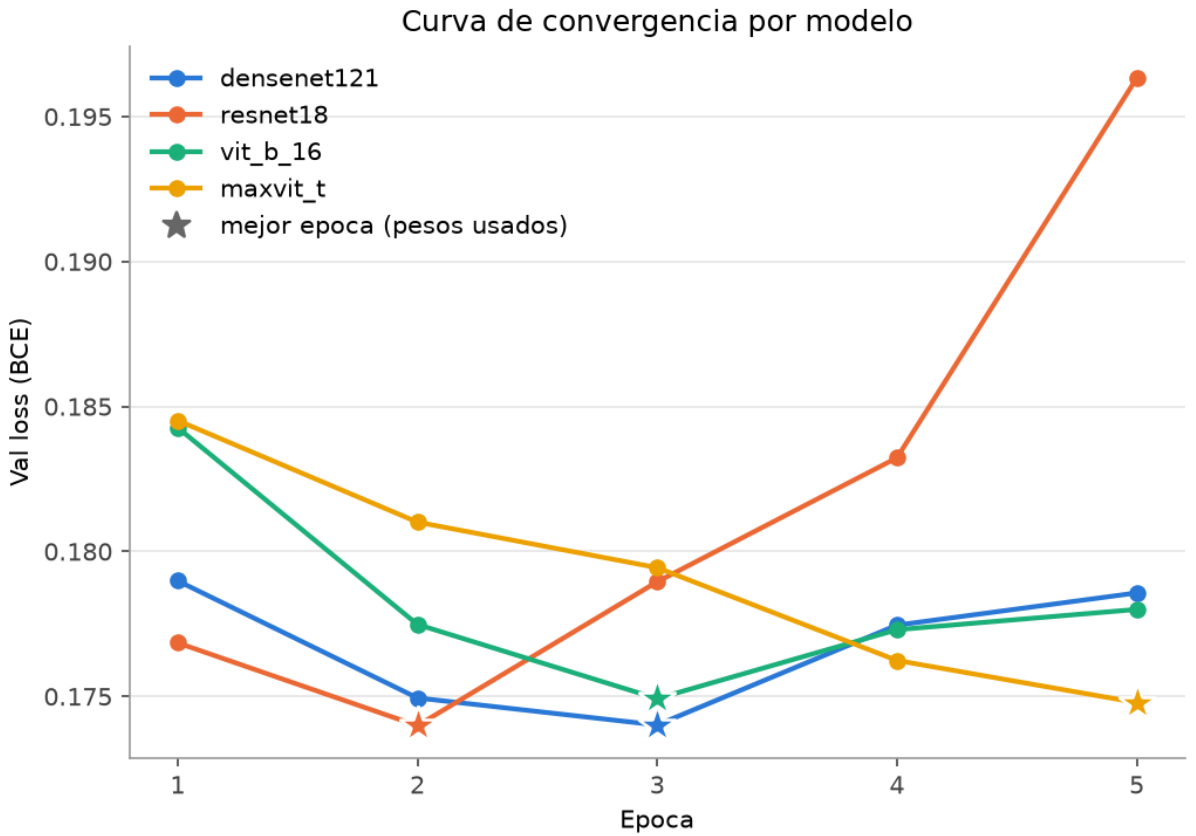
Errores distintos entre CNN, Transformer e híbrido se compensan.
Costo: correr los 4 (≈153 img/s, 134M parám.)

MaxViT-T (híbrido)

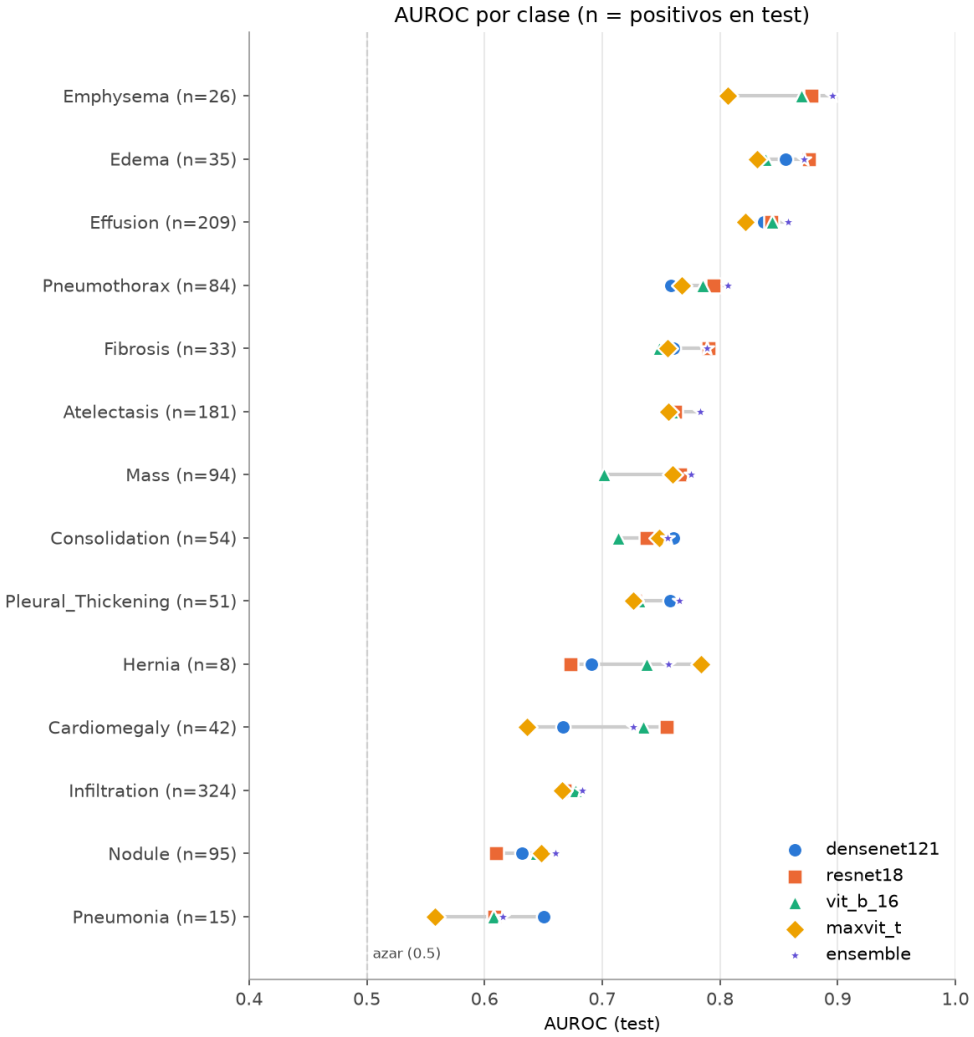
0.733

AUROC macro
mejor época: 5 de 5

Su pérdida de validación seguía bajando: con 5 épocas y solo la última capa entrenable, no llegó a converger.



Por hallazgo, la dificultad pesa más que la arquitectura



Más fáciles

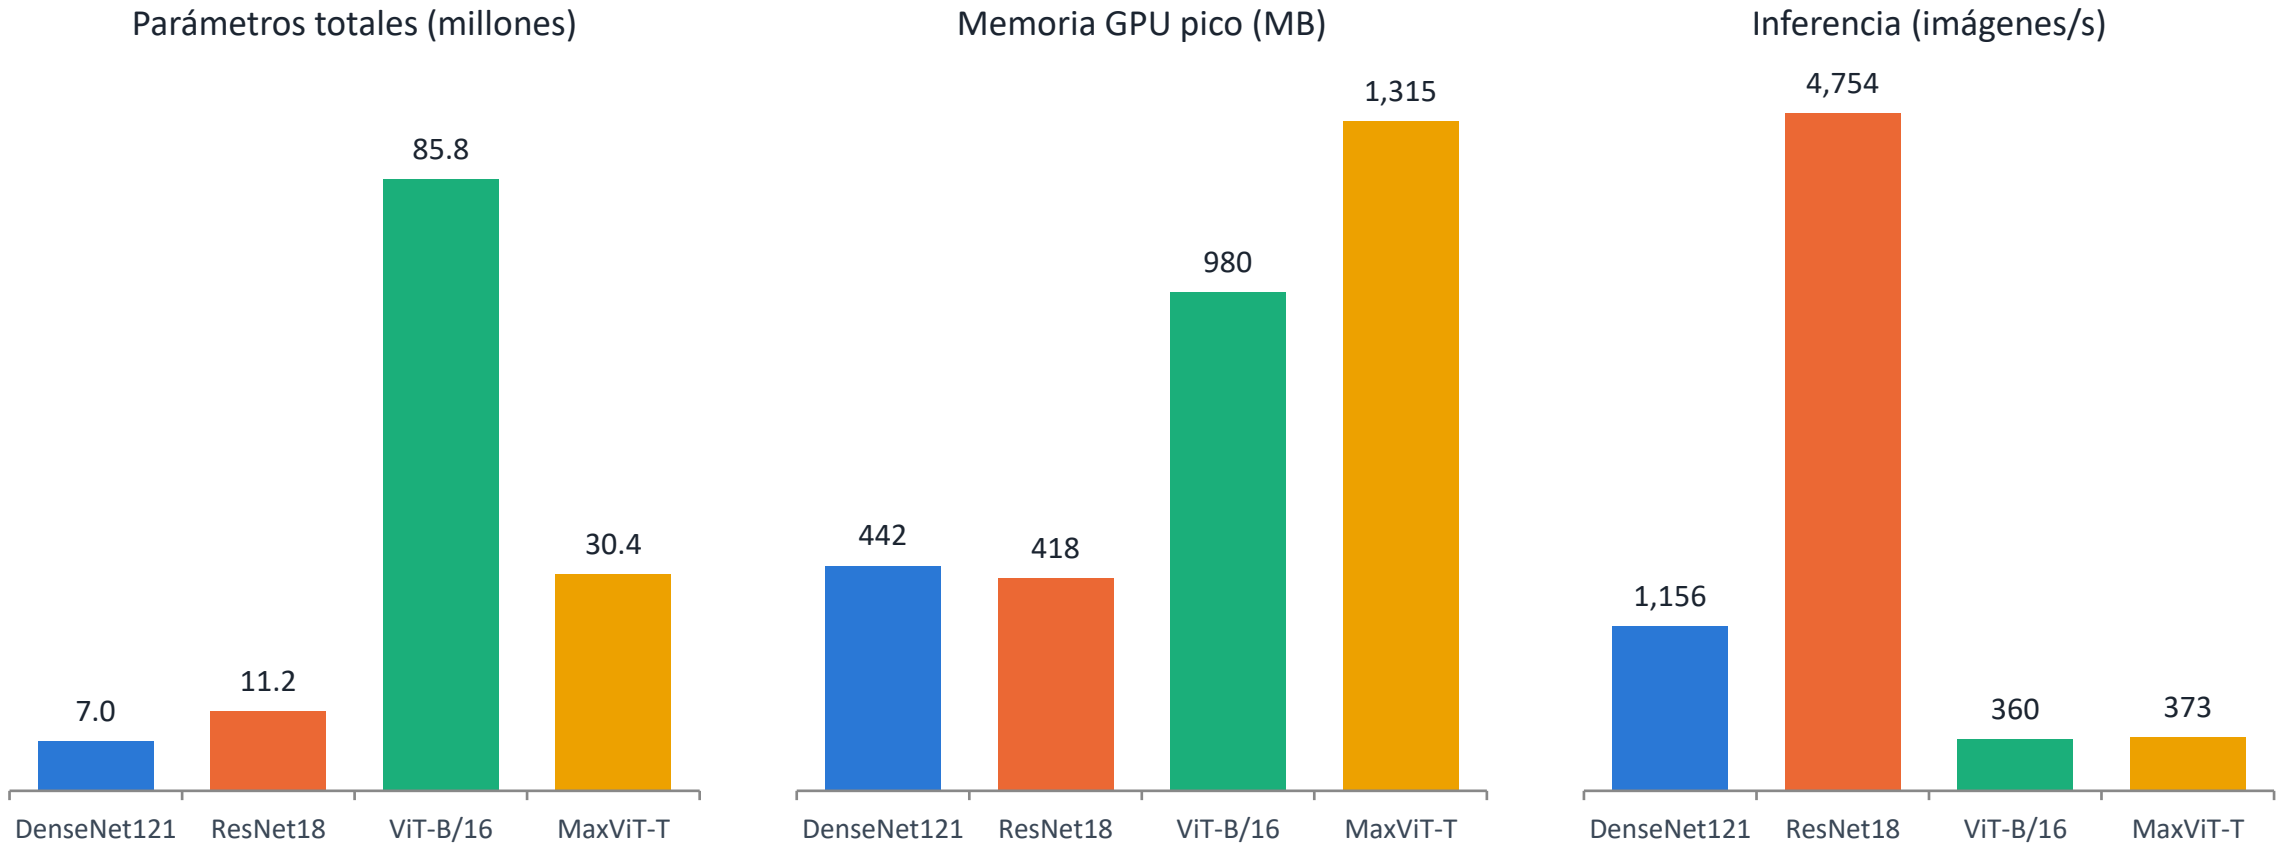
- Emphysema: 0.86
- Edema: 0.85
- Effusion: 0.84

Más difíciles

- Pneumonia: 0.61
- Nodule: 0.63
- Infiltration: 0.67

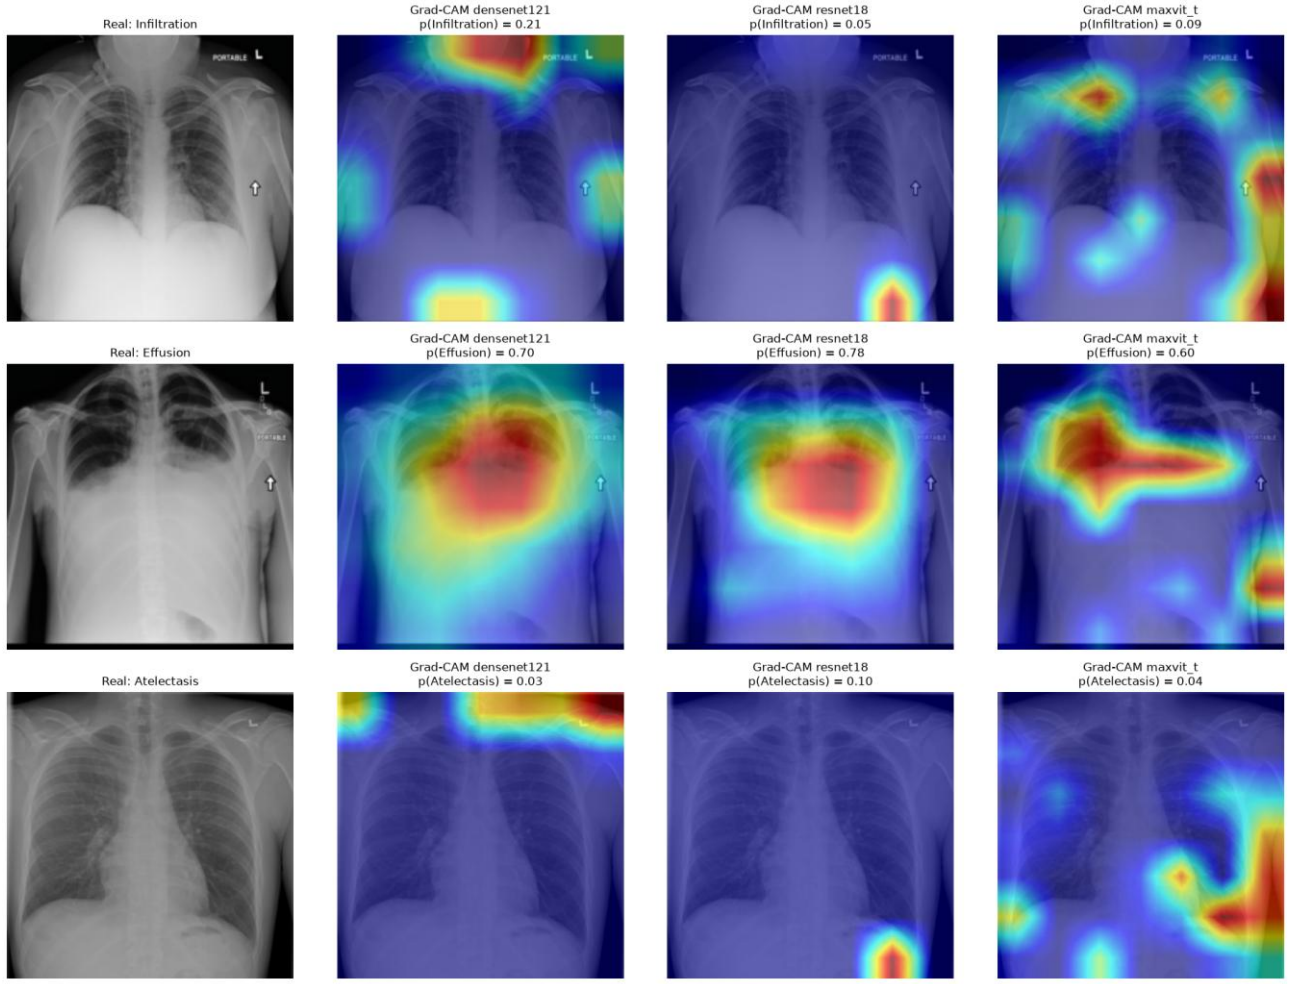
Promedio de los cuatro modelos. Los hallazgos con pocos positivos en prueba (p. ej. Hernia, n=8) tienen estimaciones inestables.

ViT y MaxViT: ~13× más lentos que ResNet18

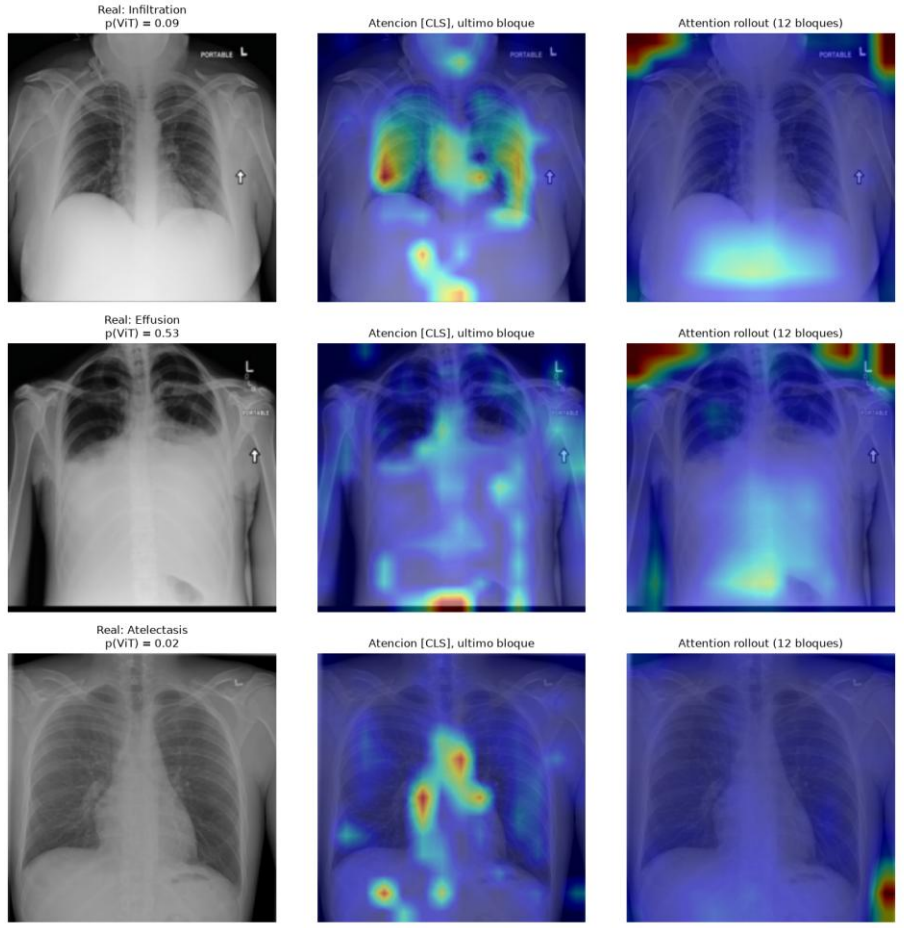


Tiempo total de entrenamiento (5 épocas): DenseNet121 190 s · ResNet18 187 s · ViT-B/16 275 s · MaxViT-T 215 s. Entre los modelos individuales, ResNet18 es el mejor compromiso: el más rápido y el que menos memoria usa.

¿Dónde miran los modelos?



Grad-CAM: DenseNet121, ResNet18 y MaxViT-T (híbrido), para la clase real



ViT-B/16: atención del último bloque y rollout

Conclusiones

Desempeño
CNN, Transformer e híbrido rinden igual con este presupuesto (AUROC 0.73–0.75); la dificultad depende más del hallazgo que de la arquitectura.

Ensemble e híbrido
Combinar los cuatro mejora a todos (AUROC 0.767). El híbrido necesita más entrenamiento para mostrar su ventaja.

Costo
ResNet18 es el mejor compromiso individual; ViT y MaxViT son ~13× más lentos sin rendir más.

Método
Split por paciente, umbral en validación, intervalos de confianza y repetir el experimento evitaron sobreinterpretar diferencias pequeñas.

Limitaciones: subconjunto de 12k imágenes (11%), etiquetas ruidosas, 5 épocas con backbone casi congelado, una semilla por corrida, 224 px. Trabajo futuro: las 112k imágenes y fine-tuning completo, aprendizaje auto-supervisado sobre radiografías sin etiquetar, y multimodalidad (edad, sexo, proyección y texto del reporte).